Trabajo Final Inteligencia Artificial I

Sistema de reconocimiento de huellas dactilares controlado por reconocimiento de voz

Autor: Julián Correa Villarreal (Legajo: 14110)
Carrera: Ingeniería en Mecatrónica — Facultad de Ingeniería, Universidad Nacional de Cuyo (UNCUYO)
Asignatura: Inteligencia Artificial I — Año 2026
Cátedra: Prof. Titular Dra. Ing. Selva S. Rivera — JTP Ing. Juan I. García

Resumen

Este trabajo presenta el diseño e implementación de un agente inteligente de control de acceso biométrico multimodal que integra visión artificial y reconocimiento de habla sobre identidades dactilares sintéticas. El sistema resuelve la verificación e identificación de tres identidades autorizadas y el rechazo de intrusos, operando mediante los comandos de voz «Reconocer», «Identificar» y «Salir». Las huellas dactilares, generadas con Anguli y sometidas a distorsiones operativas realistas, se acondicionan en cinco etapas conservando sus dimensiones íntegras sin recorte de ROI: normalización CLAHE ponderada, filtrado Mediana-Gaussiano, banco direccional de 16 filtros de Gabor, binarización adaptativa y esqueletizado de Zhang-Suen. De cada muestra se extraen 90 descriptores invariantes a rototraslación para entrenar un modelo no supervisado K-Means ($k = 3$) acoplado a una métrica de distancia euclídea equiparada con umbral experimental ($\tau = 16,89$). Paralelamente, un clasificador supervisado K-NN ($K = 5$) evalúa 392 características espectro-temporales (MFCC con normalización cepstral, ΔMFCC, Log-Mel y ZCR en 6 bloques fonéticos ponderados por ANOVA). El módulo dactilar alcanzó 100% de pureza y 100% de exactitud en prueba ($\mathbf{FRR} = 0\%$, $\mathbf{FAR} = 0\%$), y el módulo acústico logró 96,06% en validación cruzada (92,51% *Leave-One-Person-Out*), demostrando alta eficacia en tiempo real.

1. Introducción

1.1. Visión Artificial y Biometría Dactilar

La visión artificial (*Computer Vision*) dota a los sistemas computacionales de la capacidad de adquirir, procesar y analizar imágenes digitales para tomar decisiones autónomas. En el control de acceso biométrico, una huella dactilar está conformada por un patrón alternado de crestas (líneas oscuras en contacto con el sensor) y valles (surcos claros intermedios), cuyo análisis se divide en dos niveles:

1. Nivel macro-estructural (Singularidades de Galton-Henry): Define la topología global mediante puntos singulares de máxima curvatura: núcleos (*cores*, centros de giro superior) y deltas (puntos de divergencia trirradial inferior). Según su disposición, las huellas se clasifican en *Arcos* (sin núcleo ni delta), *Presillas* (un núcleo y un delta) y *Verticilos* (uno o dos núcleos y dos deltas).
2. Nivel micro-estructural (Minucias): Comprende las discontinuidades locales de las crestas, principalmente terminaciones (fin de línea) y bifurcaciones (división en dos ramas), junto con la densidad local y el conteo de crestas entre singularidades.

Dado que la captura sufre variaciones de presión, rotaciones, traslaciones, deformaciones elásticas, cicatrices y ruido, resulta indispensable acondicionar la imagen y extraer descriptores geométricos invariantes antes de aplicar algoritmos de agrupamiento.

1.2. Reconocimiento Automático de Voz

El reconocimiento de voz (*Automatic Speech Recognition*) identifica comandos hablados analizando la evolución temporal de la envolvente espectral del tracto vocal (formantes) y la articulación de vocales y consonantes. Como la onda temporal varía con el volumen, la distancia al micrófono, los silencios y el tono de cada hablante, el reconocimiento independiente del locutor emplea Detección de Actividad de Voz (VAD), transformación a la escala auditiva Mel, Coeficientes Cepstrales en las Frecuencias de Mel (MFCC) con sus derivadas dinámicas (ΔMFCC) y tasa de cruces por cero (ZCR).

1.3. Descripción del Problema a Resolver

El trabajo consiste en diseñar e implementar un agente inteligente de control de acceso biométrico gobernado por voz sobre una base de 3 identidades sintéticas autorizadas, capaz de admitir e identificar variantes distorsionadas de dichas personas y rechazar huellas intrusas. El operador interactúa mediante tres comandos de voz clasificados con K-Vecinos Más Cercanos (K-NN):

- «Reconocer»: Preprocesa la huella activa, extrae sus características y evalúa su distancia al centroide más cercano de K-Means ($k = 3$). Si es menor o igual al umbral experimental τ, informa `AUTORIZADO`; si lo supera, informa `NO AUTORIZADO`.
- «Identificar»: Si la huella fue previamente autorizada, informa a cuál identidad corresponde (`Identidad Sintética #1`, `#2` o `#3`).
- «Salir»: Finaliza de manera segura la ejecución del agente.

2. Especificación del Agente

2.1. Tipo de Agente

El sistema implementado en `agente.py` es un Agente Basado en Modelo y Basado en Objetivos que combina aprendizaje supervisado (K-NN) y no supervisado (K-Means). A diferencia de un agente reflejo simple, mantiene un estado interno mediante una máquina de estados finitos (`SIN_SELECCION`, `PENDIENTE`, `RECONOCIDO_AUTORIZADO`, `RECONOCIDO_RECHAZADO` e `IDENTIFICADO`) que garantiza la secuencia lógica de seguridad: impide ejecutar «Identificar» sin haber ejecutado previamente «Reconocer» y bloquea la identificación de muestras rechazadas como intrusas.

2.2. Especificación REAS (PEAS)

Componente	Descripción en el Sistema de Control de Acceso
Rendimiento (Performance)	• Minimizar la Tasa de Falsa Aceptación (FAR) de intrusos y la Tasa de Falso Rechazo (FRR) de autorizados. • Maximizar la pureza y exactitud de identificación entre las 3 identidades sintéticas ($k = 3$). • Maximizar la exactitud del clasificador de voz K-NN ($K = 5$) ante distintos locutores y mantener respuesta en tiempo real (< 1 s).
Entorno (Environment)	• Terminal biométrica sobre Linux (Ubuntu con PipeWire/ALSA y Wine para generación sintética en vivo con Anguli). • Repositorio de identidades autorizadas (`dataset_huellas/Personas/`), muestras de prueba e intrusas (`huellas_prueba/`, `bandeja_agente/`) y operador humano frente al micrófono.
Actuadores (Actuators)	• GUI Tkinter: Cartel de estado (`AUTORIZADO` verde / `NO AUTORIZADO` rojo / alertas en ámbar), etiqueta de identidad (`Identidad Sintética #1/#2/#3`), barras K-NN y 5 pestañas diagnósticas. • Exportación: Creación automática de reportes y gráficos PNG/WAV en `salidas_agente/`, invocación de Anguli y cierre con «Salir».

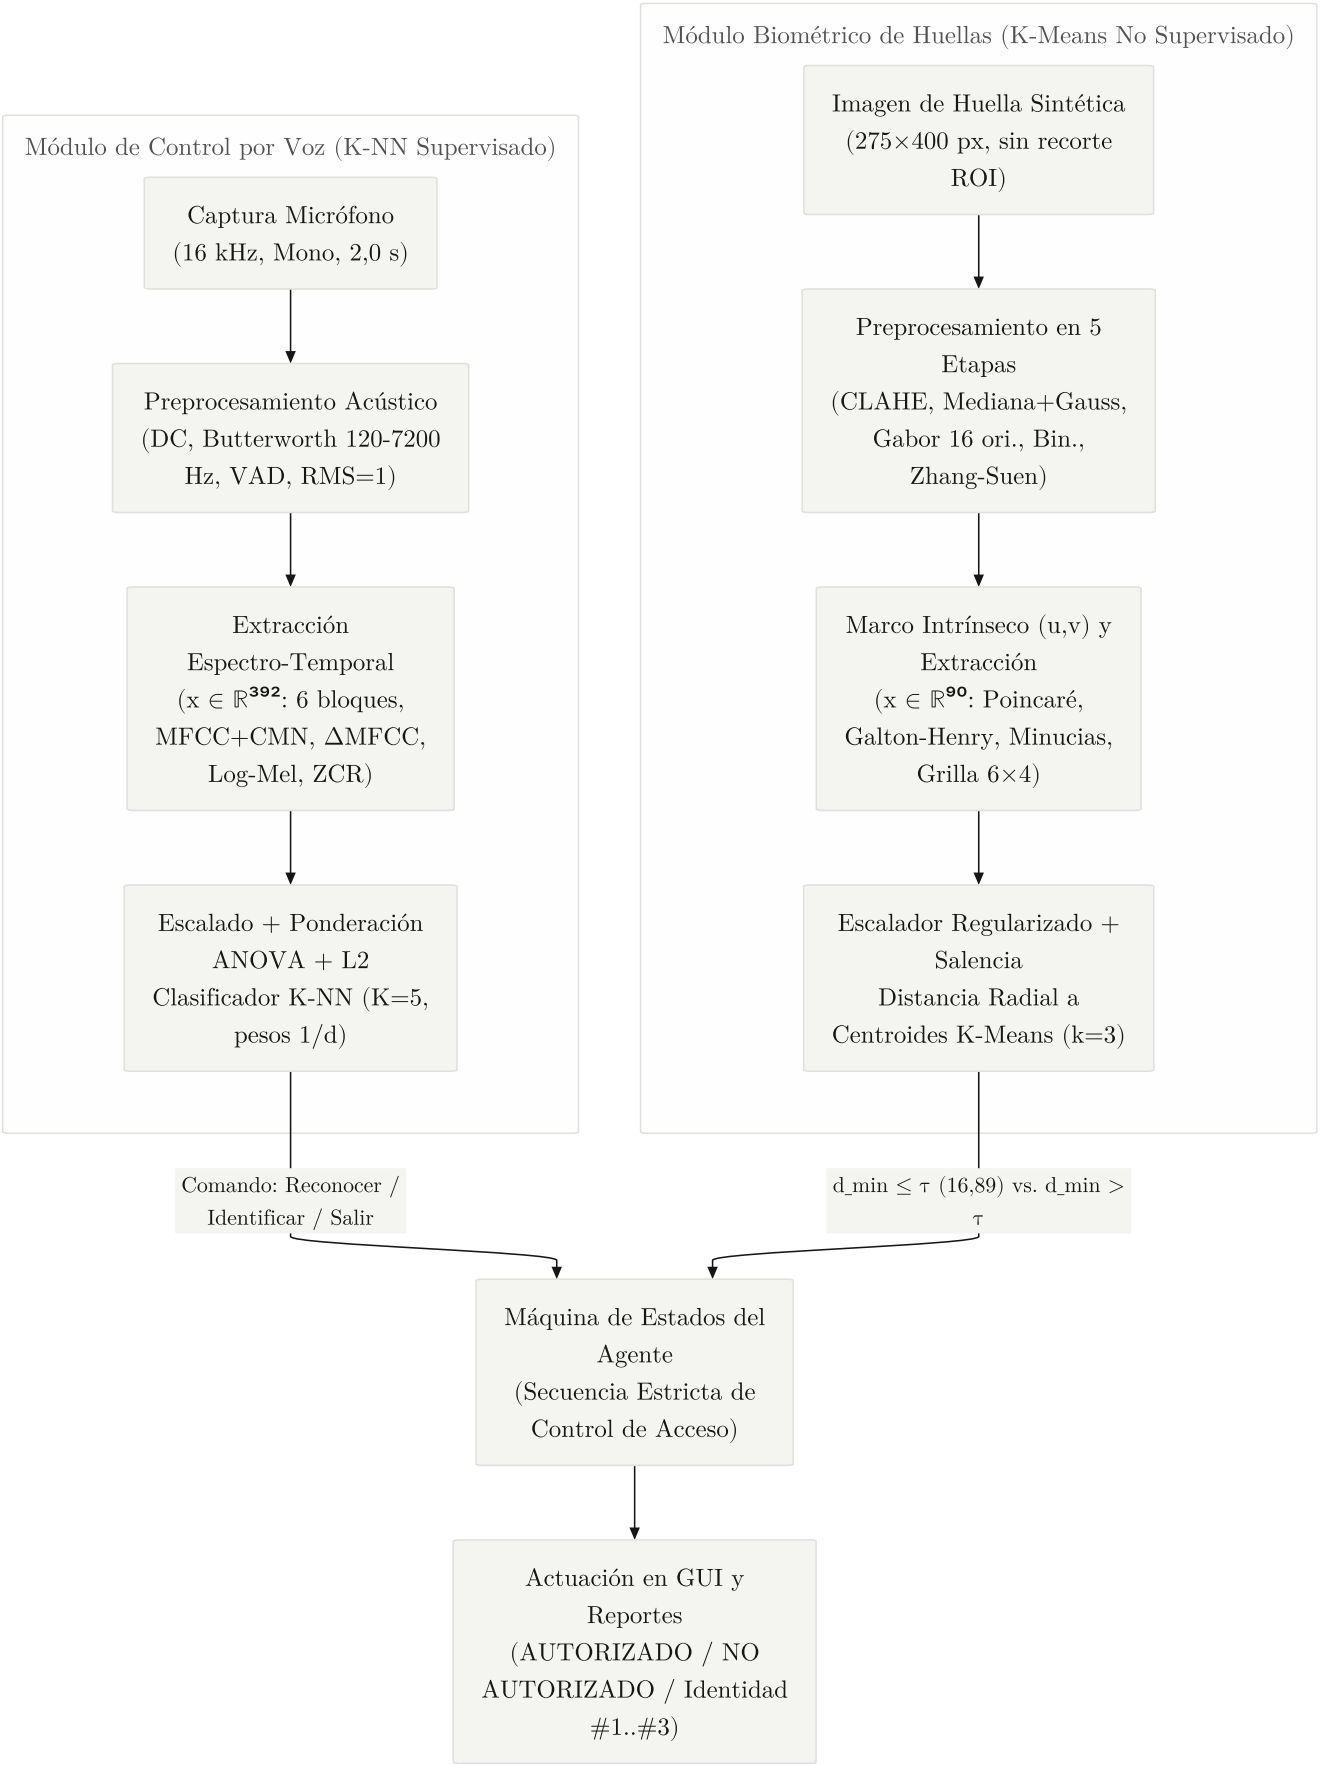
Componente	Descripción en el Sistema de Control de Acceso
Sensores (Sensors)	• Sensor Acústico: Micrófono digital PCM 16-bit mono a **16 kHz** (`arecord` / `sounddevice`) y lector de archivos `.wav`. • Sensor Óptico Simulado: Lector de imágenes de huellas en escala de grises (**275 × 400 px**) desde bandeja o generadas en vivo.

2.3. Propiedades del Entorno de Trabajo

1. Parcialmente observable: La imagen dactilar y el micrófono capturan señales afectadas por ruido, presión desigual, recortes parciales o ruido ambiente, por lo que la identidad y el comando deben inferirse estadísticamente.
2. Agente individual: El sistema opera como única entidad racional de decisión frente al operador.
3. Estocástico: Las distorsiones físicas de las huellas y la captura de voz en vivo contienen variaciones aleatorias, aunque la inferencia posterior sobre la señal digitalizada es determinista.
4. Secuencial: La validez del comando «Identificar» depende directamente del resultado obtenido en el paso previo «Reconocer».
5. Semidinámico: La muestra no cambia durante el cómputo algorítmico, pero la captura de audio ($\mathbf{2,0\ s}$) y la generación con Anguli ocurren en tiempo real mediante hilos secundarios (`threading`).
6. Continuo (discretizado): Las señales físicas continuas se discretizan a **16000 Hz** (16 bits) en audio y matrices de $\mathbf{275 \times 400\ px}$ (8 bits) en imagen.

3. Diseño del Agente y Fundamentos Teóricos

3.1. Arquitectura General del Agente



3.2. Preprocesamiento de Imágenes de Huellas Dactilares

El módulo `preprocesamiento.py` ejecuta 5 etapas secuenciales conservando íntegramente el tamaño original de **275 × 400 píxeles** sin recorte de ROI, evitando así discontinuidades artificiales en los bordes del dedo:

1. Etapa 1 — Normalización del contraste (`normalizar_contraste`): Estiramiento lineal entre los percentiles P_2 y P_{95} seguido de ecualización adaptativa CLAHE (`clipLimit = 1.8`, grilla 8×8) para recuperar zonas de baja presión. Para no amplificar ruido en el margen blanco exterior (dado que no se recorta por ROI), la salida se pondera por la desviación estándar local $\sigma_{\text{loc}}(x, y)$ en ventanas de 25×25 px, manteniendo el fondo exterior en blanco puro (255).
2. Etapa 2 — Reducción de ruido espacial (`reducir_ruido`): Aplicación de un filtro no lineal de mediana 3×3 que elimina el ruido impulsivo (*sal y pimienta*) y sella micro-poros de 1 px sin difuminar bordes, seguido de un suavizado Gaussiano 3×3 ($\sigma = 0,65$). Se descartaron ventanas mayores (5×5) para no fusionar valles adyacentes de 3--4 px de ancho.
3. Etapa 3 — Estimación de orientación local y realce con filtros de Gabor (`estimar_orientacion_y_coherencia` y `realzar_crestas_gabor`):
   - *Estimación de la dirección de las crestas:* A partir de los gradientes espaciales de intensidad (operador de Sobel) promediados en cada vecindad local, se calcula para cada píxel el ángulo dominante $\theta(x, y) \in [0, \pi)$ que siguen las crestas y un mapa de coherencia local, el cual mide qué tan definidas y paralelas son las líneas en esa región (diferenciando el área útil del dedo respecto del fondo blanco).
   - *Banco direccional de filtros de Gabor:* Se genera un banco de $N = 16$ filtros de Gabor orientados en ángulos equiespaciados entre $0°$ y $180°$ (con ventana de 17×17 px). Un filtro de Gabor actúa como un detector selectivo en frecuencia y dirección: combina una onda cosenoidal sintonizada al grosor y separación media entre crestas ($\lambda = 8,5$ px) con una envolvente Gaussiana ligeramente alargada en el sentido de la línea ($\sigma_x = 2,6$ px de ancho transversal y $\sigma_y = 4,2$ px de largo longitudinal).
   - *Reconstrucción de continuidad:* En cada punto de la huella se aplica la respuesta de los filtros del banco alineados con su ángulo local $\theta(x, y)$. Al filtrar siguiendo exactamente la inclinación de cada cresta, se suavizan las interrupciones internas (uniendo cortes provocados por poros, rayones o falta de presión) y se limpian los valles intermedios sin fusionar líneas paralelas vecinas.
4. Etapa 4 — Binarización adaptativa y depuración morfológica (`binarizar_huella`): Umbralización adaptativa Gaussiana local en ventanas de 17×17 px ($C = 4,0$) combinada con cierre morfológico en cruz de 3×3 y limpieza de componentes conexas (eliminando manchas exteriores < 28 px y rellenando poros internos < 10 px).
5. Etapa 5 — Esqueletizado topológico y poda de espolones (`esqueletizar_huella`): Adelgazamiento iterativo de Zhang-Suen (1984) que reduce las crestas binarias a curvas de 1 píxel de grosor manteniendo su conectividad, seguido de la poda de micro-ramas parásitas (espolones ≤ 3 px).

3.3. Extracción de Características Dactilares, Agrupamiento K-Means y Umbral τ

A. Marco de Referencia Intrínseco e Invarianza a Rototraslación

Como las huellas se desplazan y rotan sobre el sensor sin recorte de ROI, en `estimar_marco_intrinseco_huella` se obtiene la envolvente convexa de la zona activa del dedo, calculando su centro de masa (c_x, c_y), su ángulo de inclinación principal ϕ_{rot} y sus dispersiones elípticas $(\sigma_{\min}, \sigma_{\text{maj}})$. Todo punto (x, y) y ángulo θ se transforman al sistema intrínseco del dedo (u, v):

$$u = \frac{(x - c_x)\cos\phi_{\text{rot}} + (y - c_y)\sin\phi_{\text{rot}}}{\sigma_{\min}}, \qquad v = \frac{-(x - c_x)\sin\phi_{\text{rot}} + (y - c_y)\cos\phi_{\text{rot}}}{\sigma_{\text{maj}}}, \qquad \theta_{\text{rel}} = \theta - \phi_{\text{rot}}$$

B. Vector Canónico de 90 Características Biométricas ($\mathbf{x} \in \mathbb{R}^{90}$)

La función `extraer_caracteristicas_huella` resume cada huella en 90 descriptores divididos en 6 familias anatómicas:

Índices	Dim.	Familia de Características	Descripción Técnica y Biométrica
`0 - 2`	3	Singularidades de Poincaré (Núcleo)	Mediante el Índice de Poincaré sobre el campo direccional, detecta la cantidad de núcleos (`0` en Arcos, `1` en Presillas, `2` en Verticilos) y sus coordenadas intrínsecas $(u_{\text{core}}, v_{\text{core}})$.
`3 - 20`	18	Geometría de Deltas / Ápice de Arcos	En Presillas y Verticilos codifica la presencia, posición, distancia al núcleo, ángulo y conteo de crestas de Galton-Henry entre Core y Delta. En Arcos (sin deltas), codifica la ubicación del ápice de curvatura y 5 conteos horizontales.
`21 - 30`	10	Minucias (Crossing Number) y Morfología Global	Detecta en el esqueleto de 1 px terminaciones ($CN = 1$) y bifurcaciones ($CN = 3$). Guarda sus conteos, ratio de bifurcaciones, densidad global de crestas, centro de masa de bifurcaciones y simetría lateral izquierda/derecha.
`31 - 36`	6	Transectos Ortogonales	Conteo de crestas que cruzan 3 líneas verticales ($u \in \{-0,45, 0, +0,45\}$) y 3 líneas horizontales ($v \in \{-0,4, 0, +0,4\}$).
`37 - 84`	48	Campo Direccional en Grilla 6×4	Divide el óvalo del dedo en $6 \times 4 = 24$ celdas y extrae en cada una el ángulo relativo medio codificado como $[\cos(2\theta_{\text{rel}}), \sin(2\theta_{\text{rel}})]$.
`85 - 89`	5	Textura de Gabor y Momentos de Hu	Gradiente de respuesta direccional de Gabor en 3 franjas anatómicas (superior, media, inferior) y los 2 primeros Momentos Invariantes de Hu (ϕ_1, ϕ_2) del mapa interior de singularidades.

C. Escalado con Pesos de Salencia y Agrupamiento K-Means ($k = 3$)

En `EscaladorEstandarRegularizado`, cada descriptor x_j se estandariza y multiplica por un peso de relevancia morfológica w_j (`PESOS_SALENCIA_DEFAULT`):

$$z_j = w_j \cdot \frac{x_j - \mu_j}{\sigma_j}$$

Esto atenúa la grilla de 48 celdas ($w = 0,28$) para que no domine la distancia por simple cantidad de variables y prioriza la densidad de crestas ($w = 3,20$), la simetría lateral ($w = 2,40$), el ratio de bifurcaciones ($w = 2,20$), los transectos ($w = 2,00$) y las minucias ($w = 1,50$).

Sobre las $N = 60$ muestras autorizadas de entrenamiento (20 por persona), el algoritmo no supervisado K-Means ($k = 3$) halla los tres centroides $\mathbf{c}_1, \mathbf{c}_2, \mathbf{c}_3 \in \mathbb{R}^{90}$ minimizando la inercia intra-clúster:

$$J = \sum_{i=1}^{3} \sum_{\mathbf{z} \in C_i} \|\mathbf{z} - \mathbf{c}_i\|_2^2, \qquad \mathbf{c}_i = \frac{1}{|C_i|} \sum_{\mathbf{z} \in C_i} \mathbf{z}$$

Una vez convergidos los centroides sin usar etiquetas, el método Húngaro (Kuhn-Munkres) asocia cada centroide con su etiqueta (`Identidad Sintética #1`, `#2` y `#3`).

D. Calibración Experimental del Umbral τ y Equiparación Radial

Dado que K-Means siempre asigna el centroide más próximo, es necesario fijar una frontera radial máxima para rechazar intrusos:

1. Para cada clúster $i \in \{1, 2, 3\}$, se estima su radio natural en entrenamiento mediante la mediana y la desviación absoluta respecto de la mediana (σ_{MAD}):

$$\tau_i = \max\left(\text{mediana}_i + 2{,}25 \cdot \sigma_{\text{MAD},i},\ 1{,}02 \cdot \max_i(d)\right)$$

2. Para unificar las distintas dispersiones de cada topología ($\tau_1 = 15{,}23$, $\tau_2 = 19{,}05$, $\tau_3 = 16{,}38$), se define el umbral global único $\tau = \frac{1}{3}\sum_{i=1}^{3}\tau_i = \mathbf{16{,}89}$ y los factores de escala radial $s_i = \tau_i/\tau$. Así, para cualquier huella nueva $\mathbf{z}$, se evalúa su distancia euclídea normalizada mínima $d_{\min}$:

$$d_{\text{norm}}(\mathbf{z}, \mathbf{c}_i) = \frac{\|\mathbf{z} - \mathbf{c}_i\|_2}{s_i}, \qquad d_{\min} = \min_{i \in \{1,2,3\}} d_{\text{norm}}(\mathbf{z}, \mathbf{c}_i)$$

$$\text{Decisión}(\mathbf{z}) = \begin{cases} \text{AUTORIZADO (Identidad } c^* = \arg\min_i d_{\text{norm}}(\mathbf{z}, \mathbf{c}_i)), & \text{si } d_{\min} \le \tau = 16{,}89 \\ \text{NO AUTORIZADO (Intruso Rechazado)}, & \text{si } d_{\min} > \tau = 16{,}89 \end{cases}$$

3.4. Procesamiento de Audio y Clasificación de Voz con K-NN

A. Acondicionamiento Acústico y Recorte de Voz Activa (VAD)

En `reconocimiento_voz_knn.py`, cada señal grabada (16000 Hz, mono, 2,0 s) atraviesa cuatro pasos en `preprocesar_senal_voz`:

1. Eliminación de Offset DC: $s_0[n] = s[n] - \bar{s}$ para centrar la onda en cero.
2. Filtro pasa-banda Butterworth de 4.º orden (120 Hz – 7200 Hz): Suprime el zumbido eléctrico de 50 Hz, golpes de aire graves y ruido agudo fuera de la banda vocal.
3. Detección de Actividad de Voz (VAD adaptativo): Calcula la energía eficaz $E_{\text{RMS}}(t)$ en ventanas de 25 ms (salto de 10 ms) y recorta automáticamente el silencio inicial y final superando el umbral adaptativo $U_{\text{VAD}} = E_{15} + 0{,}18 \cdot (E_{\max} - E_{15})$.
4. Normalización de volumen (RMS = 1,0): Divide la palabra recortada por su valor eficaz para independizarla del volumen o distancia al micrófono.

B. Extracción Espectro-Temporal en 6 Bloques ($\mathbf{x} \in \mathbb{R}^{392}$)

Tras aplicar un filtro de pre-énfasis ($y[n] = x[n] - 0{,}97x[n-1]$) que realza las consonantes y formantes agudos, se extraen 14 descriptores globales (duración activa, fracción hablada, media/desvío RMS y envolvente silábica en 10 puntos) y se divide la palabra recortada en $N_{\text{seg}} = 6$ bloques temporales sucesivos ($B_1 \dots B_6$).

En cada uno de los 6 bloques se calculan 63 descriptores: 13 MFCC con Normalización de Media Cepstral (CMN) (que captura la forma del tracto vocal restando el timbre estático del micrófono/locutor), 13 MFCC absolutos, 13 derivadas dinámicas ΔMFCC (transición entre sílabas), 16 bandas de espectrograma Log-Mel, 6 bandas de contraste espectral, 1 tasa de cruces por cero (ZCR) (clave para detectar la fricativa `/s/` al inicio de *«Salir»* o al final de *«Reconocer»*) y 1 centroide espectral. Esto conforma el vector de $14 + 6 \times 63 = 392$ características.

C. Ponderación ANOVA y Clasificador K-NN ($K = 5$)

Tras estandarizar con `StandardScaler`, el `PonderadorANOVA` calcula en entrenamiento el estadístico F_j de análisis de varianza (varianza entre los 3 comandos dividida por la varianza entre las 7 personas) y pondera cada coordenada con $w_j = (F_j / \max_m F_m)^{0{,}20}$ antes de normalizar a esfera unitaria L_2. Finalmente, el clasificador supervisado K-NN ($K = 5$) busca los 5 audios de entrenamiento más cercanos $\mathcal{N}_K(\mathbf{x})$ en distancia euclídea y asigna la probabilidad de cada comando mediante votación ponderada por el inverso de la distancia:

$$P(y=c \mid \mathbf{x}) = \frac{\sum_{i \in \mathcal{N}_K(\mathbf{x})} \frac{1}{d(\mathbf{x},\mathbf{x}_i)+\varepsilon} \cdot \mathbb{I}(y_i = c)}{\sum_{j \in \mathcal{N}_K(\mathbf{x})} \frac{1}{d(\mathbf{x},\mathbf{x}_j)+\varepsilon}}, \qquad \hat{y} = \arg\max_c P(y=c \mid \mathbf{x})$$

4. Código e Implementación del Proyecto

4.1. Arquitectura Modular y Persistencia en Tiempo Real

El código fuente completo, los scripts de entrenamiento y evaluación, los modelos preentrenados y la documentación del proyecto se encuentran disponibles en el repositorio oficial de GitHub: https://github.com/jcorreavi/IA1_ProyectoFinal.
El sistema fue estructurado de forma modular en Python 3, separando claramente la generación y captura de datos, el acondicionamiento de señales, los modelos de aprendizaje automático y la interfaz del agente:

Archivo / Módulo	Rol y Responsabilidad Principal en el Sistema
`agente.py`	Agente Inteligente Principal (GUI Tkinter): Integra los modelos de voz y huellas, implementa la máquina de estados («Reconocer» → «Identificar» → «Salir»), genera huellas en vivo con Anguli y exporta reportes en `salidas_agente/`.
`reconocimiento_huellas_kmeans.py`	Biometría Dactilar y K-Means ($k = 3$): Implementa el marco intrínseco (u, v), el extractor de 90 características, los pesos de salencia, el umbral radial $\tau = 16,89$ y los gráficos PCA 2D/3D.
`preprocesamiento.py`	Acondicionamiento de Huellas: Ejecuta las 5 etapas sobre el lienzo completo de 275×400 px sin recorte de ROI, incluyendo el filtro de Gabor de 16 orientaciones y el esqueletizado vectorizado de Zhang-Suen.
`reconocimiento_voz_knn.py`	Procesamiento Acústico y K-NN ($K = 5$): Implementa el filtro Butterworth, recorte VAD, extracción de 392 características en 6 bloques, ponderación ANOVA y validación cruzada 5-Fold y LOPO.
`grabador_voz.py`	Captura y Gestión de Voz: Grabación guiada a 16 kHz mono, actualización de `dataset_voz/metadata.csv` y selección de micrófono en Linux (PipeWire/ALSA).
`generador_anguli.py` y `distorsionador.py`	Generación y Degradación de Huellas: Invocación de `Anguli.exe` vía Wine (semilla `1604` para autorizados o aleatoria para intrusos) y aplicación de 9 distorsiones físicas realistas.

Para lograr un inicio instantáneo sin recalcular filtros de Gabor ni espectrogramas sobre todo el dataset en cada arranque, ambos modelos entrenados se persisten con `joblib` (`modelo_kmeans_huellas.joblib` y `modelo_knn_voz.joblib`). Al ejecutar `agente.py`, se valida la firma del dataset y ambos modelos se cargan en memoria en ≈ 5 ms.

4.2. Evolución del Desarrollo y Dificultades Técnicas Resueltas

El desarrollo evolucionó de forma incremental en el repositorio Git del proyecto, destacándose la resolución de tres desafíos técnicos principales:

1. Bloqueo DC de audio en Linux (ALSA/PipeWire): En las primeras pruebas con `sounddevice` sobre Ubuntu, PortAudio seleccionaba por defecto una entrada analógica desconectada (`SN6140 Analog`) que entregaba una señal constante clavada en $-1,0$ DC. Se implementó un detector automático de saturación DC y el enrutamiento nativo hacia el micrófono digital activo mediante PipeWire (`wpctl`) y `arecord`.

2. Estabilidad en huellas sin deltas (Arcos) y sin recorte de ROI: En las huellas de tipo Arco (Identidad #1), el salto de intensidad entre el borde del dedo y el lienzo blanco de 275×400 **px** generaba falsas singularidades en la periferia. Se resolvió aplicando una máscara de erosión sobre la envolvente convexa, aniquilando pares de singularidades espurias cercanas (< 24 **px**) y alojando descriptores de curvatura de ápice cuando $n_{\text{deltas}} = 0$.
3. Balance de salencia frente a intrusos con topología similar: Inicialmente, las 48 celdas de orientación diluían el peso de las diferencias finas de cresta, produciendo un $\mathbf{94,83\%}$ de exactitud en las primeras pruebas preliminares. La introducción de `PESOS_SALENCIA_DEFAULT` (priorizando la densidad global de crestas y el ratio de bifurcaciones) permitió alcanzar una separación del $\mathbf{100\%}$ en el conjunto de prueba final.

5. Ejemplos de Aplicación

Durante la operación en vivo del agente (`agente.py`), cada evaluación biométrica gobernada por voz genera automáticamente una subcarpeta de auditoría en `salidas_agente/` que almacena el mosaico de preprocesamiento de la huella, el diagnóstico K-Means + PCA, los archivos `.wav` pronunciados por el usuario y los gráficos de preprocesamiento y clasificación K-NN de cada orden vocal.

En la siguiente tabla se resumen las pruebas ejecutadas en vivo sobre las tres identidades autorizadas y sobre una huella intrusa:

Caso de Prueba	Muestra Generada en Vivo	Topología Detectada	Distancias Normalizadas (d_1, d_2, d_3)	$d_{\min}$ vs. $\tau = 16,89$	Comando «Reconocer»	Comando «Identifica
Caso 1 (Id. #1)	`persona1_seed1604_arch_impr`	Arco (0 Core, 0 Delta)	$(\mathbf{8,88},\ 61,21,\ 74,22)$	$8,88 \leq 16,89$	`AUTORIZADO`	`Identidad Sintética #1`
Caso 2 (Id. #2)	`persona2_seed1604_natural_impr`	Presilla Der. (11 crestas)	$(47,82,\ \mathbf{8,98},\ 33,13)$	$8,98 \leq 16,89$	`AUTORIZADO`	`Identidad Sintética #2`
Caso 3 (Id. #3)	`persona3_seed1604_natural_impr`	Presilla Der. (14 crestas)	$(60,86,\ 32,12,\ \mathbf{7,84})$	$7,84 \leq 16,89$	`AUTORIZADO`	`Identidad Sintética #3`
Caso 4 (Intruso)	`intrusa_seed265113_whirl_impr`	Verticilo (2 Cores, 2 Deltas)	$(\mathbf{51,85},\ 67,49,\ 65,12)$	$51,85 > 16,89$	`NO AUTORIZADO`	*Bloqueado por estad*

A continuación se presentan cuatro casos completos de prueba ejecutados sobre muestras generadas en vivo con Anguli.

5.1. Caso 1: Huella Autorizada — Identidad Sintética #1 (Topología Arco)

- Muestra evaluada: `huella_anguli_persona1_seed1604_arch_impr_223142_53.jpg` (generada en vivo para Persona 1 con semilla `1604`, topología *Arch* e impresión física con ruido y rayones).
- Paso 1 — Comando de voz «Reconocer»: El usuario presiona la barra espaciadora y pronuncia *«Reconocer»*. El clasificador K-NN ($K = 5$) identifica el comando con 100,0% de confianza. El agente ejecuta las 5 etapas de preprocesamiento (Figura 1) y calcula las distancias normalizadas a los tres centroides K-Means:
  - Distancia a Centroide Id. #1: $\mathbf{8,8764}$

- Distancia a Centroide Id. #2: $61,2143$
- Distancia a Centroide Id. #3: $74,2154$
  Como $d_{\min} = 8,88 \leq \tau = 16,89$, el cartel principal cambia a verde mostrando únicamente `AUTORIZADO` y aguardando la siguiente orden.

- Paso 2 — Comando de voz «Identificar»: El usuario pronuncia *«Identificar»* (100,0% de confianza K-NN). Habiéndose cumplido la secuencia estricta previa, el agente revela la identidad asignada: `Identidad Sintética #1` (Figura 2). En las Figuras 3 y 4 se observan las 6 etapas del procesamiento acústico y la proyección PCA 2D de la orden vocal.



Figura 1: Mosaico de las 5 etapas de preprocesamiento para la muestra de Identidad Sintética #1 (Arco, 275x400 px sin recorte de ROI).

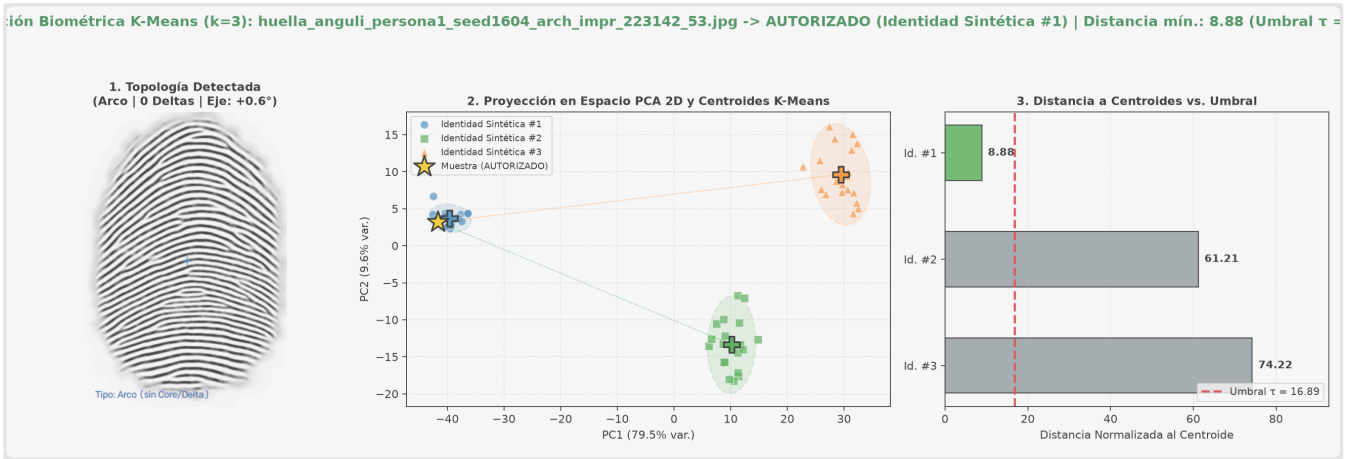


Figura 2: Evaluación biométrica K-Means (k=3) y proyección PCA 2D para el Caso 1 (AUTORIZADO -> Identidad Sintética #1, d_min = 8,88 <= 16,89).

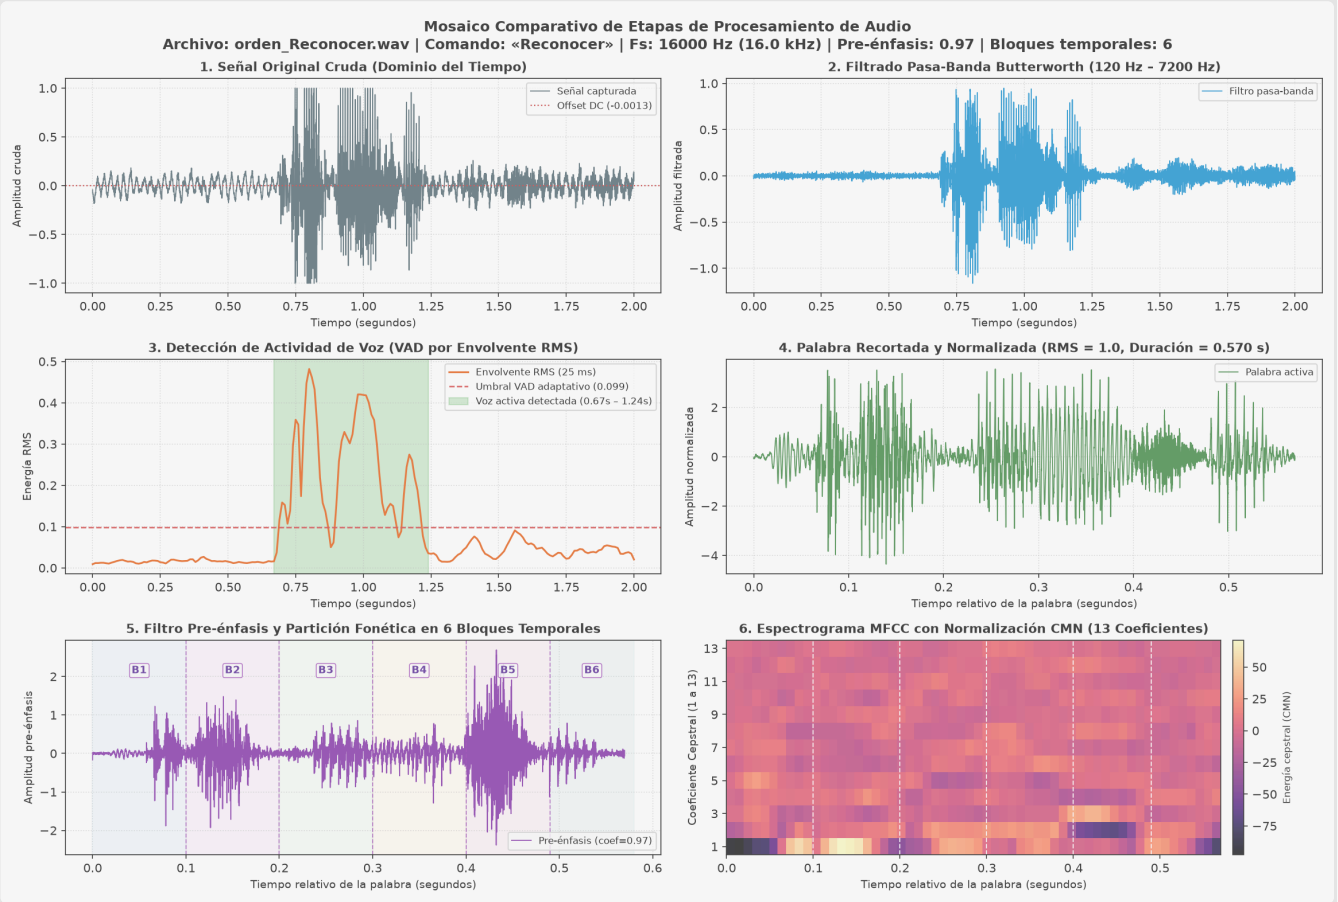


Figura 3: Mosaico de las 6 etapas de procesamiento de audio para el comando «Reconocer» pronunciado en el Caso 1.

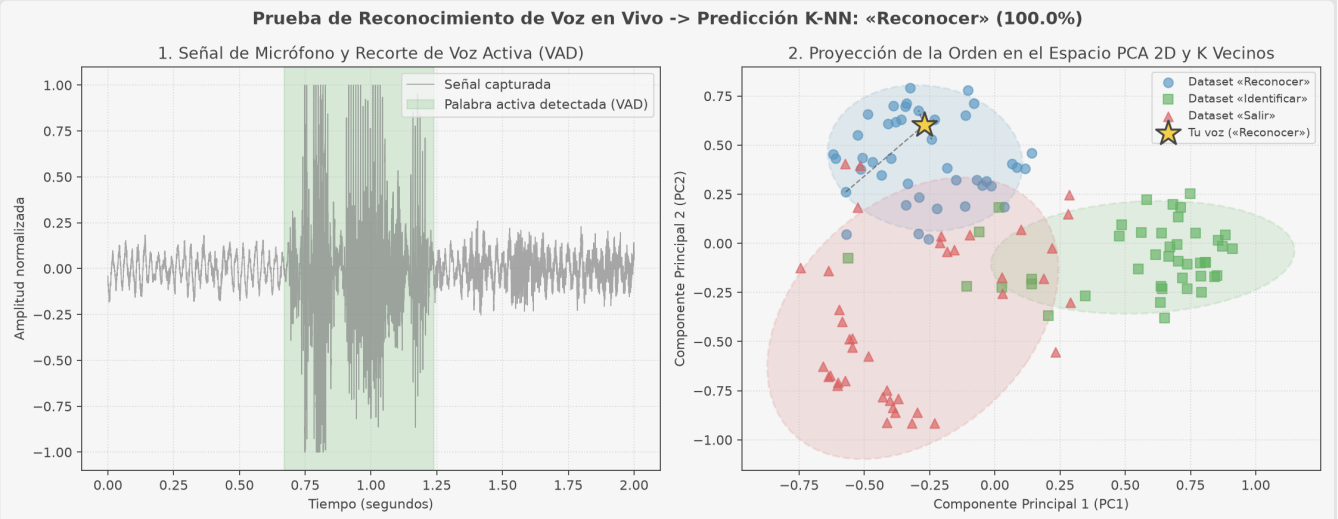


Figura 4: Recorte de voz activa (VAD) y proyección en el espacio PCA 2D junto a sus K=5 vecinos para el comando «Reconocer».

5.2. Caso 2: Huella Autorizada — Identidad Sintética #2 (Topología Presilla Derecha)

- Muestra evaluada: `huella_anguli_persona2_seed1604_natural_impr_223207_74.jpg` (generada en vivo para Persona 2 a partir del lote oficial con semilla `1604`).

- Detección topológica: El extractor localiza 1 núcleo (*Core*) y 1 delta inferior izquierdo (Presilla Derecha), contabilizando 11 crestas de Galton-Henry sobre el segmento Core-Delta con una rotación axial del dedo de $-2,4°$.
- Secuencia «Reconocer» → «Identificar»: Al pronunciar *«Reconocer»* (100,0% confianza K-NN), el sistema obtiene $d_{\min} = \mathbf{8,9816} \leq \tau = 16,8860$ (frente a $47,82$ para Id. #1 y $\mathbf{33,13}$ para Id. #3), otorgando estado `AUTORIZADO`. Al pronunciar *«Identificar»* (100,0% confianza K-NN), el agente informa `Identidad Sintética #2` (Figuras 5 y 6).

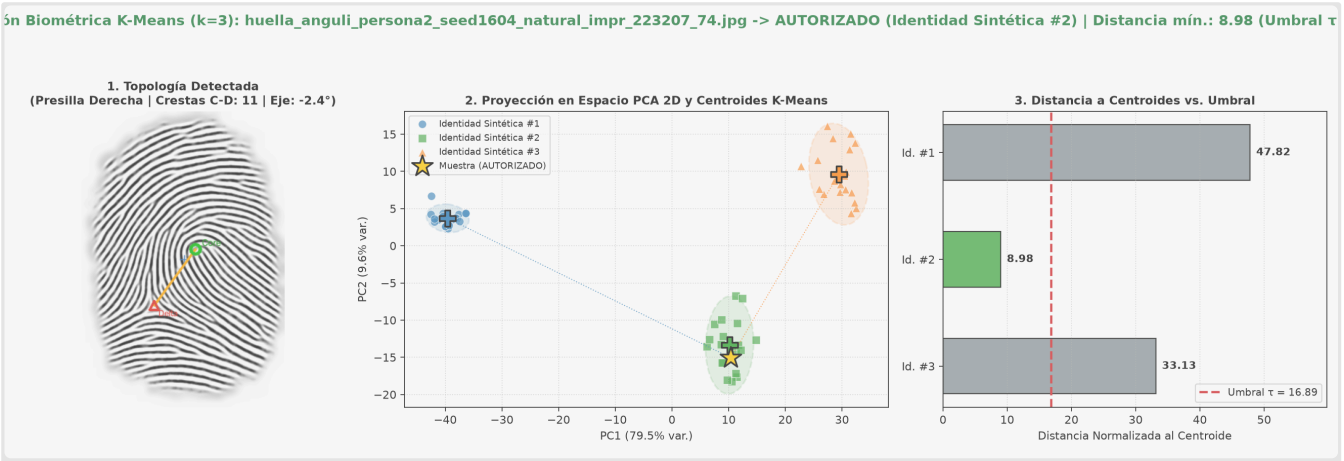


Figura 5: Evaluación biométrica K-Means (k=3) para el Caso 2 (AUTORIZADO -> Identidad Sintética #2, Presilla Derecha con 11 crestas Core-Delta, d_min = 8,98 <= 16,89).

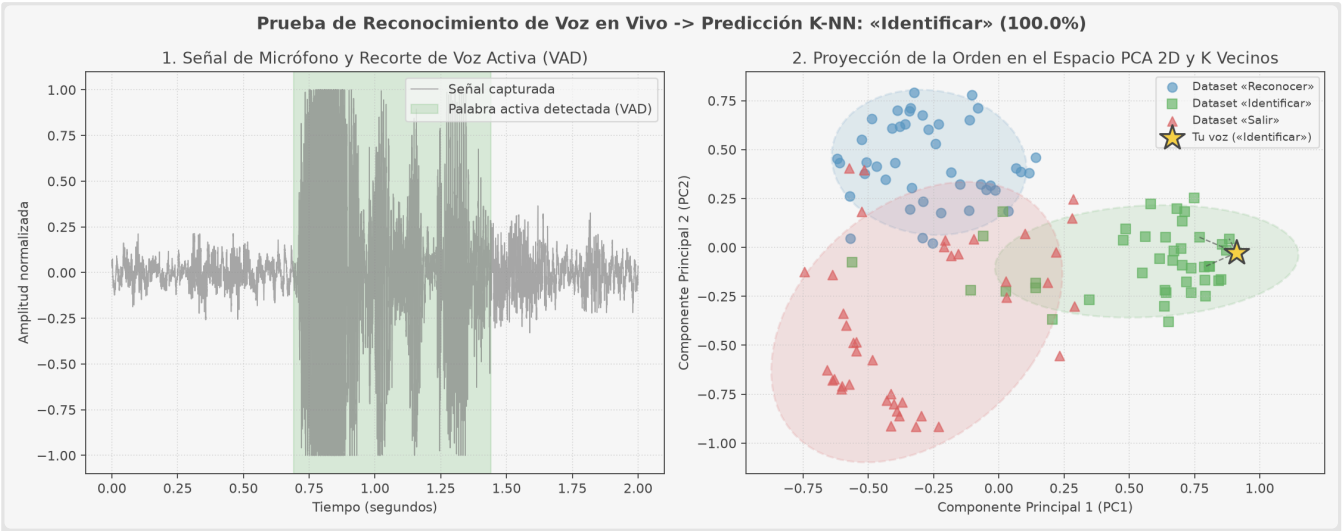


Figura 6: Diagnóstico K-NN y proyección PCA 2D de la orden de voz «Identificar» ejecutada en el Caso 2.

5.3. Caso 3: Huella Autorizada — Identidad Sintética #3 (Topología Presilla Derecha)

- Muestra evaluada: `huella_anguli_persona3_seed1604_natural_impr_223230_89.jpg` (tercera identidad sintética autorizada, semilla `1604`).
- Diferenciación fina entre presillas: Aunque tanto la Identidad #2 como la Identidad #3 pertenecen a la misma familia macroscópica (*Presilla Derecha*), el vector de 90 características distingue con holgura ambas personas gracias al mayor conteo de crestas Core-Delta (14 crestas frente a 11), la ubicación más alta del núcleo y la distribución espacial de minucias.

- Resultado: Tras los comandos *«Reconocer»* e *«Identificar»* (ambos con 100,0% de confianza en K-NN), la muestra se ubica en el centro de la elipse naranja en el plano PCA con una distancia mínima $d_{\min} = \mathbf{7,8431} \leq 16,8860$ (frente a $60,86$ hacia Id. #1 y $32,12$ hacia Id. #2), identificándose correctamente como `Identidad Sintética #3` (Figura 7).

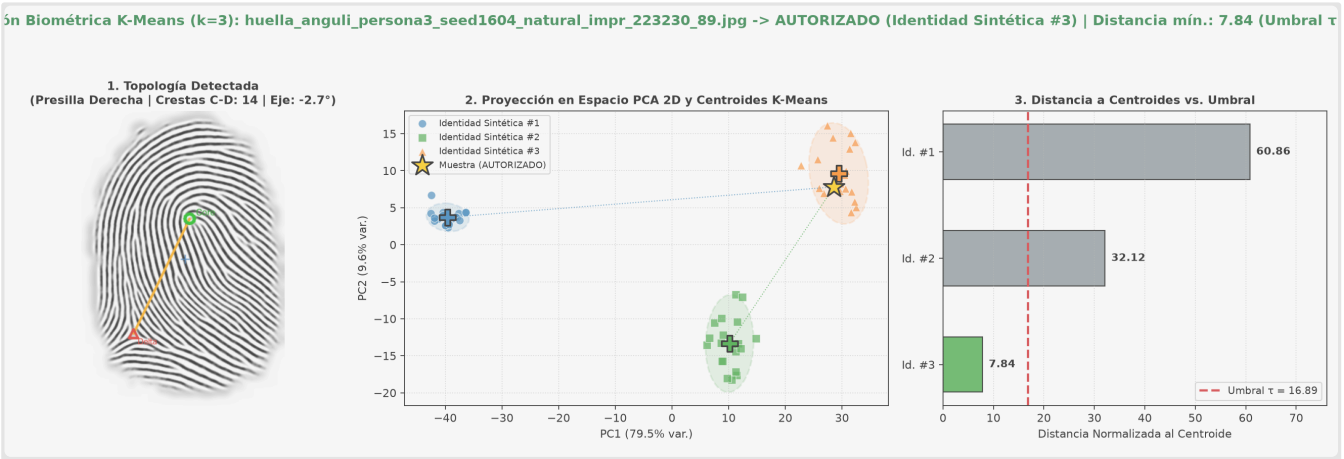


Figura 7: Evaluación biométrica K-Means (k=3) para el Caso 3 (AUTORIZADO -> Identidad Sintética #3, Presilla Derecha con 14 crestas Core-Delta, d_min = 7,84 <= 16,89).

5.4. Caso 4: Huella Intrusa (No Autorizada) y Comando «Salir»

- Muestra evaluada: `huella_anguli_intrusa_seed265113_whirl_impr_223255.jpg` (generada mediante el botón de huella intrusa con semilla aleatoria `265113`).
- Evaluación con «Reconocer»: El índice de Poincaré detecta una estructura birradial de Verticilo con doble núcleo y dos deltas laterales (14 y 13 crestas Core-Delta). Las distancias euclídeas normalizadas a los tres centroides autorizados resultan:
  - Distancia a Centroide Id. #1: $\mathbf{51,8474}$
  - Distancia a Centroide Id. #2: $67,4926$
  - Distancia a Centroide Id. #3: $65,1228$

  Dado que la distancia mínima ($51,85$) supera ampliamente el umbral experimental ($\tau = 16,89$), el agente rechaza la muestra encendiendo el cartel rojo `NO AUTORIZADO` (Figura 8). Si el operador intenta pronunciar *«Identificar»* sobre esta muestra rechazada, la máquina de estados mantiene el bloqueo e informa `ACCESO DENEGADO (Intruso / No registrado)`.
- Cierre con «Salir»: Finalmente, el operador pronuncia el comando *«Salir»* (reconocido con 100,0% de confianza por K-NN, Figuras 9 y 10), tras lo cual el agente registra el evento en la bitácora y cierra la aplicación de forma segura.

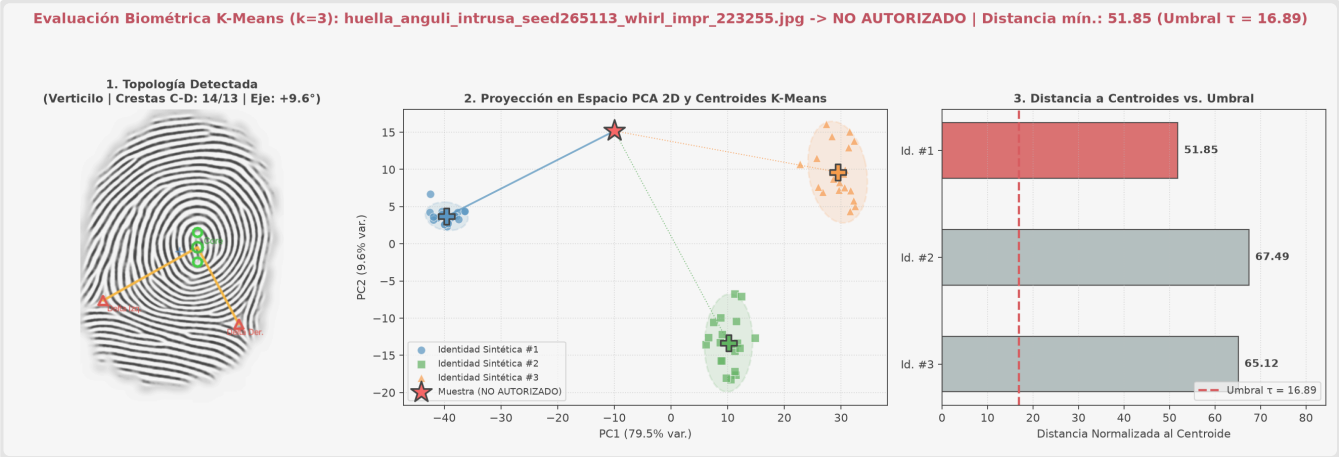


Figura 8: Evaluación biométrica K-Means (k=3) para el Caso 4 (Huella Intrusa rechazada como NO AUTORIZADO: d_min = 51,85 > umbral 16,89).

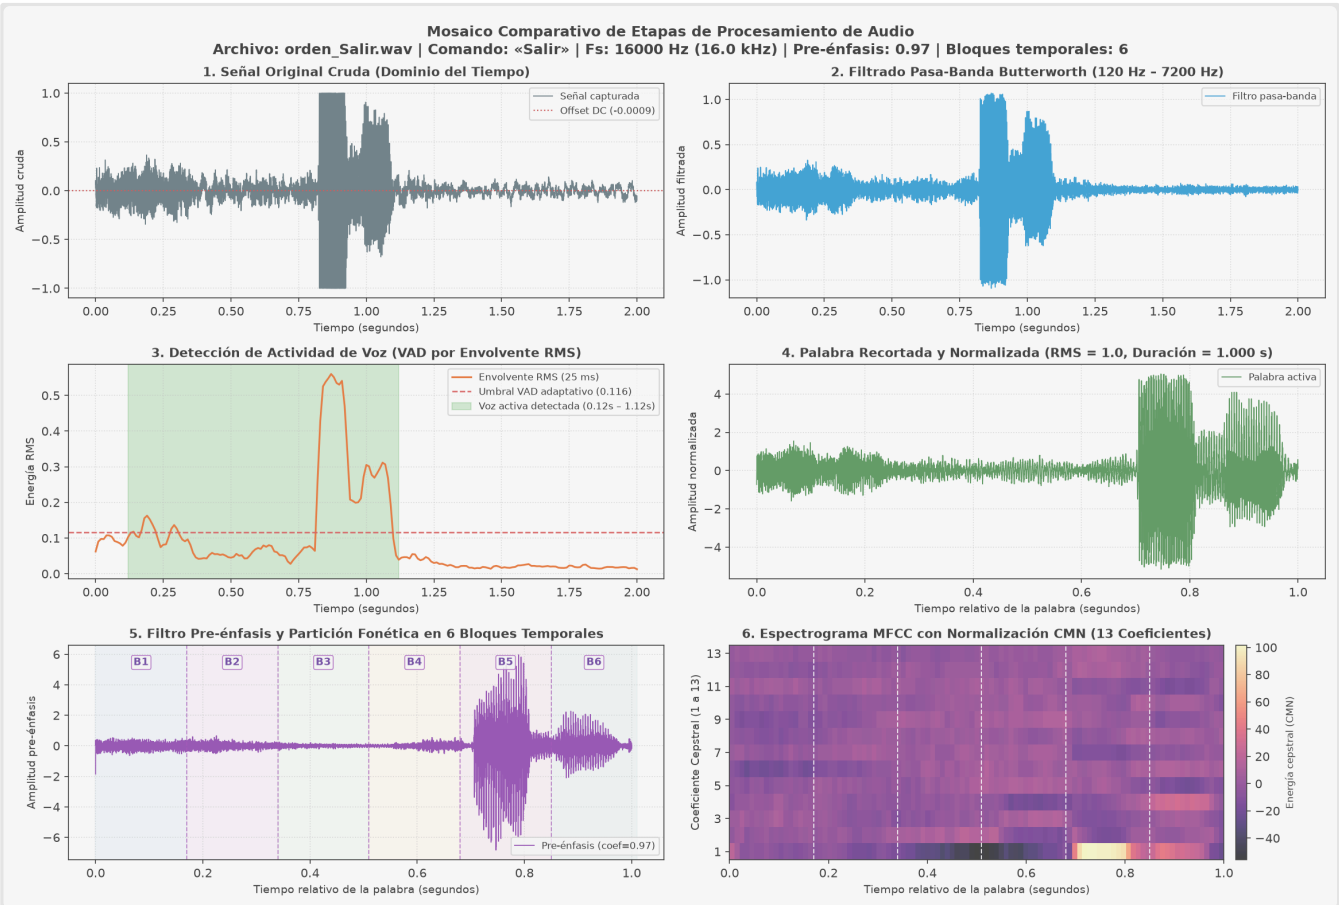


Figura 9: Mosaico de las 6 etapas de procesamiento acústico para el comando «Salir» (nótese la alta energía fricativa inicial de la 'S' en el bloque B1).

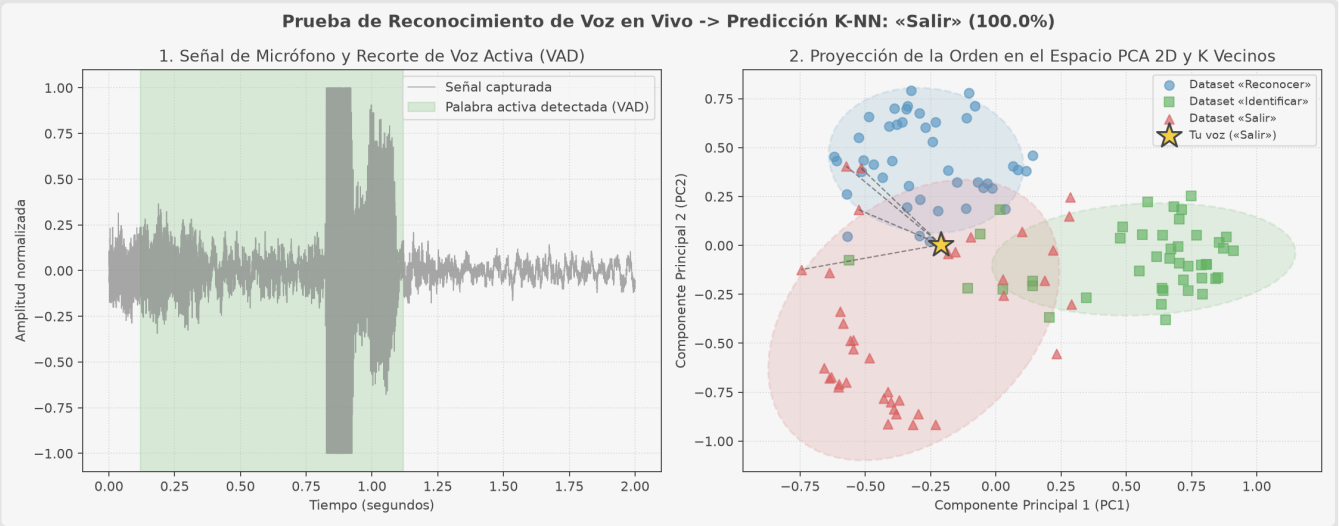


Figura 10: Proyección en el espacio PCA 2D y vecindario K-NN (K=5) para la orden de cierre «Salir».

6. Resultados Experimentales y Análisis PCA

6.1. Descripción y Generación de los Datos Utilizados

- Dataset Sintético de Huellas Dactilares: Generado con Anguli (semilla `1604`, 275×400 px) y enriquecido con `distorsionador.py` mediante combinaciones de 9 transformaciones físicas (deformación elástica no lineal, distorsión ondulatoria, presión morfológica por erosión/dilatación, corrección gamma, rotación $\pm 15°$, traslación ± 15 px, ruido Gaussiano, sal y pimienta y corte parcial de borde).
  - *Conjunto de Entrenamiento Autorizado (`dataset_huellas/Personas/`):* 60 imágenes (20 por cada una de las 3 identidades autorizadas: Id. #1 Arco, Id. #2 y #3 Presillas Derechas). Es el único conjunto empleado para entrenar K-Means y calibrar el umbral τ.
  - *Conjunto de Prueba (`huellas_prueba/`):* 55 imágenes independientes compuestas por 33 muestras autorizadas (15 de Id. #1, 9 de Id. #2 y 9 de Id. #3) y 22 muestras intrusas de identidades no registradas.
- Dataset de Comandos de Voz (`dataset_voz/`): Compuesto por 127 grabaciones reales (16 kHz, mono, 2,0 s) pronunciadas por 7 personas diferentes (`Persona_01` a `Persona_07`), balanceadas en 43 «Reconocer», 43 «Identificar» y 41 «Salir».

6.2. Estadísticas de Clasificación y Análisis PCA en Huellas Dactilares (K-Means)

- Desempeño en entrenamiento ($N = 60$): Pureza no supervisada del $100,00\%$ ($60/60$) y Coeficiente de Silueta de $0,5958$. Distancia media $= 11,00$, mediana $= 10,69$, $\sigma_{\text{MAD}} = 2,20$, máximo autorizado $= 16,55$ y umbral calibrado $\tau = 16,89$.
- Desempeño en prueba ($N = 55$): Exactitud global del $100,00\%$ ($55/55$), con Tasa de Falso Rechazo $\text{FRR} = 0,00\%$ ($33/33$ autorizadas aceptadas e identificadas correctamente) y Tasa de Falsa Aceptación $\text{FAR} = 0,00\%$ ($22/22$ intrusas rechazadas con $d_{\text{norm}} \geq 17,88$).

Clase / Identidad Real (Prueba)	Precisión (Precision)	Sensibilidad (Recall)	F1-Score	Soporte (Muestras)
Identidad Sintética #1 (Arco)	1,0000	1,0000	1,0000	15

Clase / Identidad Real (Prueba)	Precisión (Precision)	Sensibilidad (Recall)	F1-Score	Soporte (Muestras)
Identidad Sintética #2 (Presilla)	1,0000	1,0000	1,0000	9
Identidad Sintética #3 (Presilla)	1,0000	1,0000	1,0000	9
Intruso (No Autorizado)	1,0000	1,0000	1,0000	22
Total / Promedio Ponderado	1,0000 (100%)	1,0000 (100%)	1,0000 (100%)	55

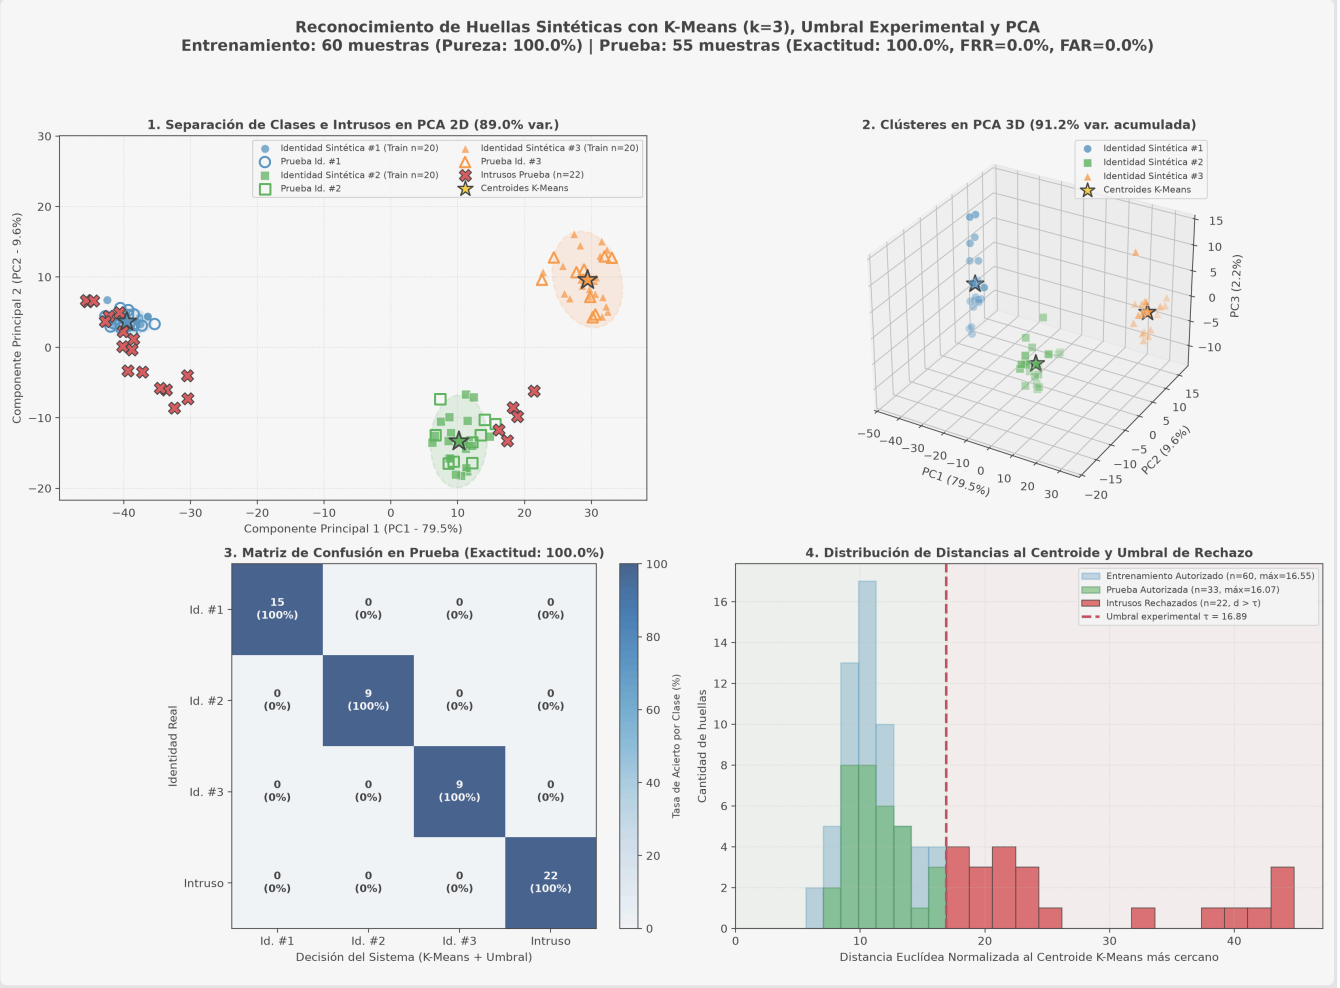


Figura 6: Análisis de huellas dactilares con K-Means (k=3): proyecciones PCA 2D/3D, Matriz de Confusión y distribución de distancias frente al umbral tau = 16,89.

Interpretación de PCA y justificación del umbral $\tau = 16,89$ (Figura 6):
Aunque en el plano 2D algunas cruces rojas de intrusos parecen proyectarse cerca de las elipses, en el espacio completo de 90 dimensiones ponderado por salencia todas quedan fuera de la hiperesfera de aceptación. El histograma del Panel 4 confirma que la recta $\tau = 16,89$ divide sin solapamiento todas las muestras autorizadas ($d_{\text{norm}} \leq 16,55$, izquierda verde) de la totalidad de las muestras intrusas ($d_{\text{norm}} \geq 17,88$, derecha roja).

6.3. Estadísticas de Clasificación y Análisis PCA en Reconocimiento de Voz (K-NN)

El modelo acústico K-NN ($K = 5$) alcanzó una exactitud del $96,06\%$ ($122/127$ aciertos) en Validación Cruzada Estratificada de 5 Pliegues (5-Fold CV) y una exactitud media del $92,51\%$ bajo evaluación

Leave-One-Person-Out (LOPO) (entrenando con 6 personas y evaluando sobre una 7.ª persona desconocida):

Comando de Voz	Precisión (Precision)	Sensibilidad (Recall)	F1-Score	Soporte (Audios)
«Reconocer»	0,9762	0,9535	0,9647	43
«Identificar»	0,9545	0,9767	0,9655	43
«Salir»	0,9512	0,9512	0,9512	41
Exactitud Global / Promedio	0,9608	0,9606	0,9606 (96,06%)	127

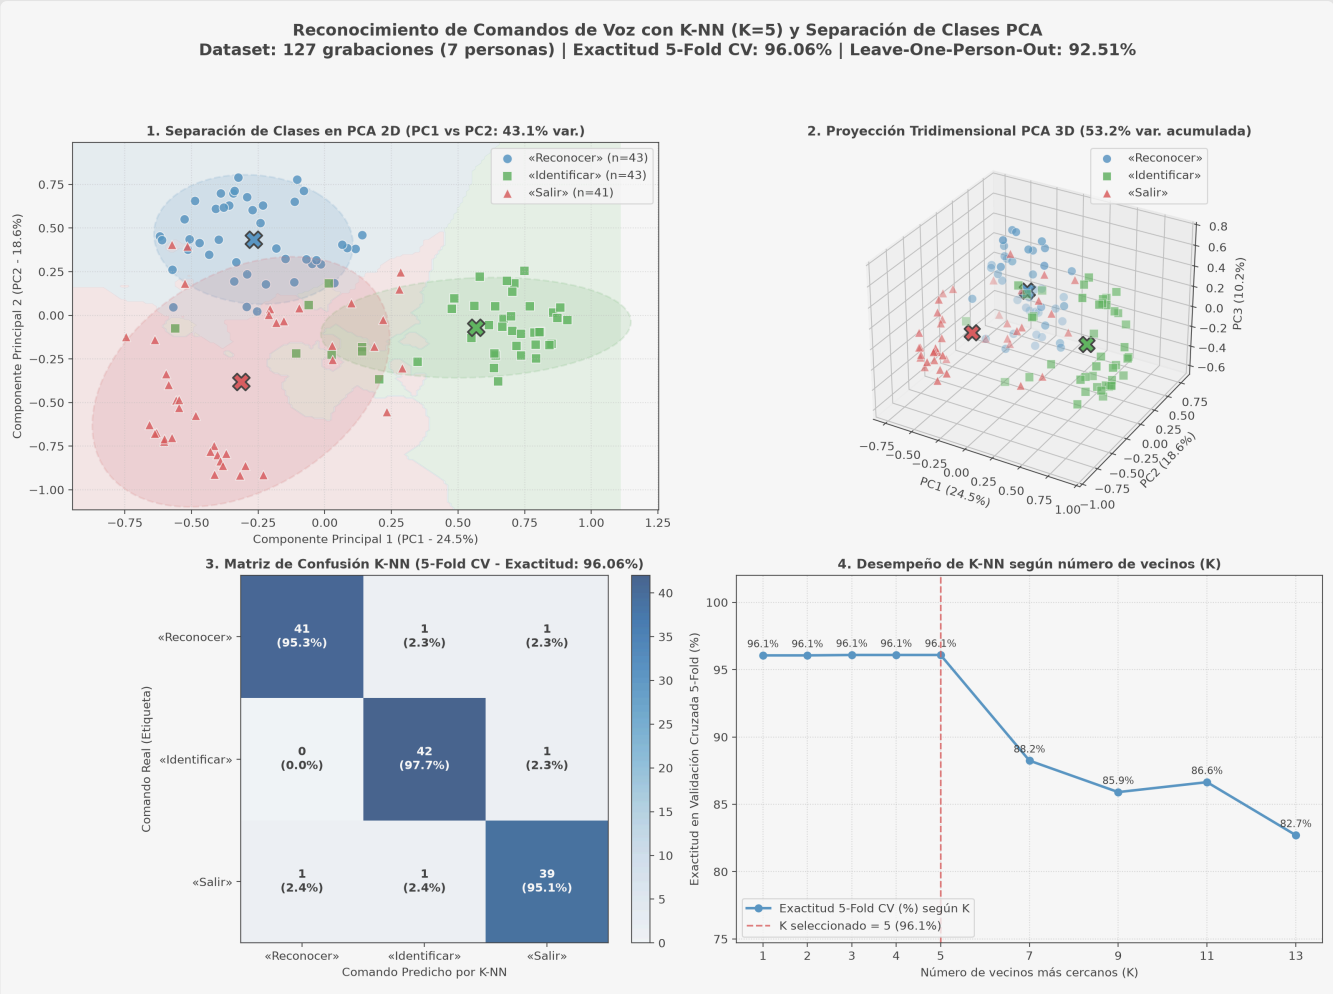


Figura 7: Evaluación del clasificador de voz K-NN (K=5): proyecciones PCA 2D y 3D, Matriz de Confusión 5-Fold CV y curva de exactitud según el número de vecinos K.

Interpretación de PCA acústico y justificación de $K = 5$ (Figura 7):

1. Proyección PCA 2D y 3D: Las dos primeras componentes concentran el $43,1\%$ de la varianza y las tres primeras el $53,2\%$. «Identificar» (verde) se ubica hacia $\mathbf{PC1} > 0$ por su mayor duración de 5 sílabas, mientras que «Reconocer» (azul, $\mathbf{PC2} > 0$) y «Salir» (rojo, $\mathbf{PC2} < 0$) se separan verticalmente según el bloque temporal donde aparece la fricativa `/s/`.
2. Elección experimental de $K = 5$: La curva de sensibilidad del Panel 4 muestra una meseta óptima de $96,1\%$ entre $K = 1$ y $K = 5$, cayendo luego para $K \geq 7$ ($88,2\%$) debido a que cuatro de los siete locutores registraron entre 4 y 5 tomas por comando (por lo que pedir más de 5 vecinos fuerza a incluir muestras lejanas). Elegir $K = 5$ aprovecha el punto más robusto de la meseta óptima,

promediando 5 votos ponderados por distancia sin perder exactitud frente a ruidos puntuales del ambiente.

7. Conclusiones

7.1. Conclusiones Generales y Eficiencia del Sistema

El sistema desarrollado cumple satisfactoriamente todos los objetivos propuestos:

1. Importancia del acondicionamiento y la invarianza geométrica: La combinación del banco de 16 filtros de Gabor, el marco intrínseco (u, v) y la ponderación de salencia permitió agrupar e identificar las huellas con 100% de exactitud sin recortar la imagen por ROI. Del mismo modo, el recorte VAD, la normalización cepstral (CMN) y el ponderador ANOVA permitieron clasificar comandos de voz con alta precisión entre múltiples hablantes.
2. Operación en tiempo real: Gracias a la caché en disco con `joblib`, el agente inicia en ~ 5 ms. En vivo, procesar y evaluar una huella toma ~ 100 ms y clasificar un comando de voz toma < 35 ms.

7.2. Ventajas, Limitaciones y Trabajos a Futuro

- Ventajas: Alta explicabilidad visual y matemática (distancias euclídeas auditables frente a $\tau = 16,89$, visualización de singularidades Core/Delta y vecindario K-NN en PCA), robustez ante hablantes nuevos ($92,51\%$ LOPO) y generación de pruebas en vivo integrada con Anguli.
- Limitaciones actuales: Sensibilidad a oclusiones severas que recorten más del 35% de la huella (desplazando el centro del óvalo intrínseco), captura de voz en ventana fija de $2,0$ s activada por pulsador y geometría esférica por clúster en K-Means.
- Trabajos a futuro: Incorporar verificación local de grafos de minucias (*Bozorth3*) para casos limítrofes al umbral τ, modelar matrices de covarianza completas por clúster mediante Modelos de Mezclas Gaussianas (GMM) o distancia de Mahalanobis, e implementar escucha continua por *streaming* con detección automática de inicio de voz.

8. Bibliografía y Referencias

1. Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.
2. Hong, L., Wan, Y., & Jain, A. (1998). Fingerprint image enhancement: Algorithm and performance evaluation. *IEEE Transactions on PAMI*, 20(8), 777–789.
3. Davis, S., & Mermelstein, P. (1980). Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences. *IEEE Trans. ASSP*, 28(4), 357–366.
4. Ansari, A. H. (2011). *Generation and storage of large synthetic fingerprint database (Anguli)*. Indian Institute of Science (IISc).
5. Documentación oficial de OpenCV, Scikit-Learn, Librosa y SciPy.

9. Uso de Inteligencia Artificial Generativa

9.1. Herramientas Utilizadas y Propósito

Se utilizaron asistentes de IA generativa (ChatGPT — OpenAI y Gemini en VS Code / Antigravity) como apoyo para la estructuración de código en Python, diseño de la interfaz gráfica en Tkinter/Matplotlib, consulta de librerías de procesamiento de señales (`librosa`, `OpenCV`, `PipeWire/ALSA`) y revisión de redacción. La generación de los datasets, la experimentación, la validación de que todas las

imágenes conservaran 275×400 px sin recorte de ROI y el ajuste de umbrales fueron realizados y verificados experimentalmente por el autor.

9.2. Ejemplos de Prompts Utilizados

Durante el desarrollo se redactaron prompts detallados para especificar los requisitos funcionales, la estructura de datos y los criterios de auditoría de cada módulo del sistema (`grabador_voz.py`, `reconocimiento_voz_knn.py`, `preprocesamiento.py`, `reconocimiento_huellas_kmeans.py` y `agente.py`). Por razones de extensión y espacio en el presente informe, se transcribe a continuación de forma íntegra únicamente el último de ellos, correspondiente a la implementación del módulo de reconocimiento de huellas dactilares con K-Means.

1. Prompt para el módulo de captura del dataset de voz (`grabador_voz.py`):

   "Desarrollá un programa en Python para grabar y organizar un dataset de comandos de voz para mi proyecto final de Inteligencia Artificial I... Debe mostrar un menú de consola que permita: 1. Elegir la persona que realizará las grabaciones... 2. Elegir el comando entre «Reconocer», «Identificar» y «Salir»... Guardá cada grabación como un archivo WAV en mono y generá un archivo `metadata.csv`."

2. Prompt para el módulo de preprocesamiento de huellas (`preprocesamiento.py`):

   "Implementá el módulo de preprocesamiento de imágenes de huellas dactilares sintéticas... Requisitos: 1. Inspeccioná el proyecto y las imágenes disponibles. 2. No realices recorte por ROI; procesá la imagen completa y conservá sus dimensiones originales. 3. Implementá una secuencia de 5 etapas que incluya normalización del contraste, reducción de ruido, realce de crestas con Gabor, binarización y esqueletizado..."

3. Prompt para el módulo de reconocimiento de huellas con K-Means (`reconocimiento_huellas_kmeans.py`):

   "Implementá el módulo de reconocimiento de huellas dactilares sintéticas en Python, respetando el PDF del trabajo final de IA1 y la estructura existente del proyecto.

   Usá `reconocimiento_voz_knn.py` como referencia para el estilo del código, la organización en funciones, los menús interactivos, la visualización de resultados y el manejo de errores. Adaptá esas ideas al problema de huellas, sin copiar la lógica de K-NN ni el procesamiento de audio.

   Funcionalidades del menú:
   1. Analizar dataset: contar huellas autorizadas e intrusas, revisar archivos y mostrar las cantidades por identidad.
   2. Preprocesar imágenes: reutilizar el módulo existente si lo hay. Procesar la imagen completa, sin recorte por ROI, y conservar los originales.
   3. Extraer características: obtener descriptores que permitan distinguir huellas, justificando su elección.
   4. Entrenar K-means: utilizar `k=3` para las tres identidades autorizadas y guardar el modelo.
   5. Evaluar resultados: mostrar métricas, matriz de confusión y errores, incluyendo la detección de intrusos.
   6. Experimentar: permitir cambiar temporalmente `k` y el umbral de aceptación/rechazo, comparar resultados y justificar el umbral experimentalmente. Diferenciá claramente el `k` de K-means del parámetro de vecinos de K-NN.
   7. Probar una nueva huella: solicitar una imagen, procesarla y mostrar `AUTORIZADO` o `NO AUTORIZADO`, identidad asignada, distancia al centroide y umbral aplicado.
   8. Ver gráficos: generar PCA 2D, varianza explicada y gráficos de distancias, guardando los resultados para el informe.
   9. Salir.

   Requisitos importantes:
   - Tengo 3 identidades autorizadas con 28 imágenes cada una y también imágenes intrusas.

- Utilizá una división reproducible entre entrenamiento, validación y prueba. Mi propuesta inicial es reservar 3 imágenes por identidad para prueba y usar las 25 restantes para entrenamiento; ajustá el diseño si hace falta para calibrar el umbral sin contaminar la prueba final.
- Entrená los centroides con identidades autorizadas. Utilizá las intrusas para evaluar el rechazo, no como una cuarta identidad autorizada.
- Mantené idénticos el preprocesamiento y la extracción de características durante el entrenamiento y las nuevas predicciones.
- No sobrescribas datos originales ni inventes resultados.
- Guardá los modelos, parámetros, métricas y gráficos para reutilizarlos sin repetir innecesariamente el procesamiento.
- Procurá una arquitectura modular, con funciones claras y un menú sencillo de usar.

Antes de programar, inspeccioná los archivos existentes y adaptate a las rutas y estructuras reales. Después implementá los cambios necesarios, entregando código completo y ejecutable.

Finalmente, auditá el código y ejecutá pruebas cuando sea posible. Informá qué verificaste realmente y explicá brevemente cómo utilizar el programa y qué hace cada módulo, ya que todavía estoy aprendiendo Python."